Discussion: Analysis of Adversarial Attacks – FGSM, PGD

본 과제에서는 MNIST 와 CIFAR-10 데이터셋에 대해 두 가지 적대적 공격 기법 FGSM(Fast Gradient Sign Method), PGD(Projected Gradient Descent)을 적용하고 유효성을 분석하였다.

Dataset	Attack Method	ϵ=0.05	ϵ=0.1	ϵ=0.2	ϵ=0.3
MNIST	FGSM Targeted	0.50	5.50	29.00	24.00
	FGSM Untargeted	6.50	25.50	68.50	89.50
	PGD Targeted	8.00	41.50	**100.00**	**100.00**
	PGD Untargeted	22.00	82.50	**100.00**	**100.00**
CIFAR-10	FGSM Targeted	51.50	33.50	15.50	9.50
	FGSM Untargeted	99.50	98.50	92.50	90.00
	PGD Targeted	**100.00**	**100.00**	**100.00**	**100.00**
	PGD Untargeted	**100.00**	**100.00**	**100.00**	**100.00**

1. Why are PGD more effective than FGSM?

두 공격 기법을 각각 적용해본 결과, PGD 공격이 모든 설정에서 FGSM 보다 훨씬 높은 성공률을 보였다. 특히 CIFAR-10 데이터셋에서 PGD 는 FGSM 이 어떤 ϵ 에 대해서도 이뤄내지 못했던 100%의 정확도를 모든 실험 설정 상에서 달성하였다. 기울기 방향을 따라 한 번만 업데이트하는 FGSM 에 비해 작은 보폭으로 여러 번 반복적으로 업데이트하며 최적의 방향을 찾아내는 방식인 PGD 가 일반적으로 더욱 강력한 알고리즘임을 시사한다.

2. Why are Untargeted attacks more effective than Targeted attacks?

모든 데이터셋과 ε 에 대해서 Untargeted 공격이 Targeted 공격보다 높은 성공률을 보였다. 이는 Untargeted 공격이 현재 label 의 확률만을 낮추는, 즉 다른 모든 class 의 확률을 높이는 방식인 반면, Targeted 공격이 특정 class 의 확률만을 올려야 하는 문제인 점에 기인한다. 이런 특징들로 인해 Targeted 공격은 공격 범위가 좁고 정확도가 떨어지며 난이도가 높다.

3. How does ε affect the trade-off between attack success and perturbation visibility?

ε 은 공격의 강도를 결정하는 파라미터로, 일반적으로 ε 이 커질수록 (특히 PGD 에서) 공격에 사용되는 노이즈의 분포 space 가 넓어지며, 공격의 다양성이 확보되어 더욱 효과적인 공격 방법을 찾게 된다. 그러나 이는 반대로 인간의 눈에 노이즈가 쉽게 발각될 수 있게 됨을

의미하기도 한다. 본 과제에서의 시각화 결과(result/MNIST_PDG_Untargeted_eps0.3.png 와 result/CIFAR-10_PGD_Untargeted_eps0.3.png 참조) MNIST 는 $\varepsilon = 0.3$ 에서도 배경 대비 노이즈가 허용 가능한 수준이었으나, CIFAR-10 과 같은 복잡한 이미지 데이터셋에서는 $\varepsilon = 0.3$ 적용 시 이미지가 심하게 왜곡되어 공격의 은밀성이 눈에 띄게 저하되었다.

4. Why does the FGSM attack success rate on the CIFAR-10 dataset diminish as ε increases?

본 과제에서 가장 주목할 점은, 위에서 ε 이 커질수록 공격이 효과적이라고 논설한 것과는 다르게, CIFAR-10 데이터셋에서 ε 이 증가함에 따라 FGSM 의 공격 성공률이 오히려 감소하는 현상이 관찰되었다는 것이다.

Decision Boundary 의 복잡도와 그로 인한 오버슈팅을 원인으로 볼 수 있다. CIFAR-10 은 실제 사물 또는 동물이 담긴 3 채널(RGB) 컬러 이미지로, Decision Boundary 가 매우 비선형적이고 복잡하게 형성되어 있으며 탐색 영역 자체도 넓고 고차원적이다. 따라서 큰 보폭으로 업데이트를 수행하는 FGSM 방식은 유효 공격 영역을 지나쳐버리는 오버슈팅을 자주 초래하게 된다. 반면 MNIST 는 배경과 객체의 구분이 매우 뚜렷한 1 채널 흑백 이미지로, Decision Boundary 가 상대적으로 단순하고 명확하며, class 간의 거리도 feature space 내에서 CIFAR-10 에 비해 넓다. 따라서 기울기 방향으로 크게 움직이더라도 유효 공격 영역을 벗어날 확률이 적고 오버슈팅이 적다.

또한 PGD 는 CIFAR-10 에 대해 모든 실험 설정에서 100%의 성공률을 달성하였는데, 이는 복잡한 경계면 상에서도 공격 지점을 안정적으로 찾아낼 수 있음을 시사한다.

즉, 데이터셋이 복잡할수록 단순한 FGSM 보다 비선형적이고 세밀한 PGD 알고리즘이 더욱 효과적이다.